

Apprentissage et adaptation d'un agent de rassemblement de troupeaux

*Mars 2026
Deep Reinforcement
Learning*

LECTUREUR Arthur

SHAMSI Meysam

Lien vidéo :

<https://filesender.renater.fr/?s=download&token=cb6390f6-8f36-412f-9fbf-6e9cbfd342bf>

Introduction, Choix Techniques et Paramétrage

Ce projet vise à résoudre un problème complexe de rassemblement de troupeaux (shepherding) à l'aide d'algorithmes apprentissage par renforcement. L'objectif est d'entraîner un agent autonome (le berger) à guider une ou plusieurs entités (les moutons) vers une zone cible.

Pour mener à bien cette étude, nous avons initialement trois algorithmes : PPO, TD3 et DQN. Face à des temps d'entraînement prohibitifs dépassant les cinq heures pour TD3 et à une forte instabilité initiale, nous avons pris la décision technique d'abandonner cet algorithme. Notre étude se concentre donc sur une comparaison rigoureuse entre l'algorithme PPO, qui traite des vecteurs d'observation continus, et l'algorithme DQN, qui s'appuie sur une perception visuelle (images) de l'environnement.

Afin de mener à bien nos expériences de manière rigoureuse, nous avons optimisé les scripts d'exécution (train.py et test.py) en y intégrant une gestion dynamique des hyperparamètres. Les modèles entraînés de zéro (Train from Scratch) ont bénéficié d'une phase d'apprentissage longue sur 2 000 000 de timesteps. Par ailleurs, nous avons automatisé la logique du Curriculum Learning (via un argument -cl) : cette méthode charge les poids du modèle précédent, réinitialise l'état de l'optimiseur pour favoriser une nouvelle exploration, et réduit la durée d'entraînement à 1 000 000 de timesteps, divisant ainsi notre empreinte de calcul par deux.

Enfin, pour garantir la viabilité statistique de nos résultats (Success Rate, Average Reward, Average Duration) et en extraire l'écart-type (l'incertitude), les phases de test ont été systématiquement paramétrées pour s'exécuter sur une moyenne de 1000 épisodes (-n 1000).

Environnements, Modifications Physiques et Performances de Référence

L'entraînement de nos agents s'est déroulé sur trois niveaux de complexité croissante : un environnement statique (Niveau 1), un environnement dynamique où le mouton possède un mouvement aléatoire (Niveau 2), et enfin un environnement contraint par la présence d'un obstacle physique (Niveau 3). Afin de modéliser l'évolution de la difficulté entre ces différents niveaux, nous avons apporté une modification structurelle au code de la simulation physique fournie initialement (shepherd_env.py).

Nous avons implémenté le mode `active_sheep`, qui redéfinit la règle de déplacement autonome des moutons selon la logique suivante :

```
139         if dist < self.repulsion_radius:
140             # Comportement de fuite (Si le berger est proche)
141             move += (vec / (dist + 1e-6)) * 0.05
142         elif self.active_sheep:
143             # Comportement aléatoire (Si le berger est loin ET active_sheep est True)
144             move += np.random.uniform(-0.01, 0.01, size=2)
```

Dans la version initiale (exclusivement utilisée pour le Niveau 1), les moutons étaient purement "réactifs" : ils restaient totalement immobiles tant que le chien de berger n'entrait pas dans leur rayon d'action. Bien que parfaite pour initier l'agent aux mécaniques de base, cette logique manquait de réalisme. L'ajout de ce comportement stochastique (elif `self.active_sheep`) permet d'introduire un bruit permanent. Lorsque l'agent s'éloigne, les moutons non surveillés commencent à dériver de manière aléatoire, simulant de manière beaucoup plus fidèle le comportement d'un véritable troupeau. Cette modification est fondamentale pour justifier les Niveaux 2 et 3, car elle force l'intelligence artificielle à anticiper et corriger en temps réel les trajectoires d'entités mobiles, augmentant significativement la difficulté de la tâche.

Afin de valider la viabilité physique de ces environnements, nous avons d'abord évalué trois comportements de références (Baselines). Le tableau ci-dessous regroupe l'ensemble des métriques de référence pour le **Niveau 1 (1 mouton)** sur 1000 épisodes :

Algorithme Niveau 1	Success Rate	Average Reward	Averag Episode Length	Temps d'entraînement
Rule-Based	100.0 %	2699.73	31.7 steps	N/A
Lazy	10.0 %	-3501.69	450.2 steps	N/A
Tipsy	8.0 %	217.65	463.6 steps	N/A
PPO	53.0 %	1101.08	214.36 steps	~ 2.0 heures
DQN	18.0 %	-1745.07	410.3 steps	~ 1.3 heures
TD3	15.0 %	-3369.41	425.1 steps	> 5.2 heures

A l'inverse, notre algorithme expert codé en dur (Rule-Based) valide parfaitement la logique de l'environnement, atteignant un taux de réussite de 100 avec un mouton, et de 94% avec trois moutons. Les modèles Lazy (immobile) et Tipsy (mouvement aléatoire) affichent des taux de succès marginaux (10% à 20%), confirmant qu'une stratégie intelligente est indispensable. L'ajout des barres d'erreur ($\pm$) sur nos graphiques permet désormais d'attester de la stabilité de ces résultats.




Figure 1 : Comparaison des performances initiales (Niveau 1) avec incertitudes statistiques.

Apprentissage et Curriculum (1 Mouton)

L'entraînement d'un seul mouton a permis d'établir une preuve de concept solide. Dès le Niveau 1, l'agent PPO prend une avance décisive (58.1% de réussite moyenne), résolvant l'environnement deux fois plus vite que DQN qui peine à généraliser (15.9% de succès).

Le passage au Niveau 2 a été l'occasion de tester différentes méthodes de transfert d'apprentissage. Les résultats statistiques montrent que l'utilisation directe (Direct Use) du modèle PPO entraîné au Niveau 1 résiste excellemment bien au bruit stochastique, conservant un taux de succès de $60.7\% \pm 3.0\%$. L'approche par Curriculum Learning (fine-tuning du modèle statique sur le niveau dynamique) maintient une performance très robuste de $53.2\% \pm 3.1\%$, surpassant ainsi un entraînement repris entièrement de zéro (Train from Scratch, $48.5\% \pm 3.1\%$). De son côté, DQN reste incapable de dépasser les 26% de succès, confirmant les limites de l'approche visuelle sur des cibles erratiques.




Figure 2 : Impact de la méthode d'apprentissage sur le Niveau 2 (Mouton Actif).

Cependant, face à l'introduction d'un obstacle géométrique (Niveau 3), la dynamique s'est inversée. Le modèle PPO entraîné depuis zéro ($54.5\% \pm 3.1\%$) a surpassé le modèle issu du Curriculum Learning ($46.3\% \pm 3.1\%$) et le Direct Use (qui chute à 44.2%). L'agent a en effet dû 'désapprendre' ses anciens réflexes de trajectoire en ligne droite pour assimiler sainement la notion de contournement. Un agent "vierge" a donc été avantagé face à cette nouvelle topologie.




Figure 3 : Impact de la méthode d'apprentissage face à un obstacle géométrique (Niveau 3).

Le Défi de la Dimensionnalité (3 moutons)

L'une des limites majeures identifiées lors de ce projet concerne la mise à l'échelle vers un système multi-entités. En appliquant nos modèles sur un troupeau de trois moutons, sans modifier la structure fondamentale du vecteur d'observation, nous nous sommes heurtés au 'mur de la dimensionnalité'.

Les modèles d'apprentissage profond (PPO et DQN) s'effondrent de manière drastique, plafonnant entre 1% et 5% de réussite sur tous les niveaux. En multipliant simplement les coordonnées d'entrée le réseau de neurones échoue à conceptualiser le groupe en tant qu'entité unique. L'agent tente alors d'interagir avec les moutons de manière isolée, ce qui disloque le troupeau.




Figure 4 : Effondrement des capacités de l'intelligence artificielle face à la gestion de 3 moutons.

Environnement Multi-Agent (Niveau 4)

En raison des contraintes matérielles sévères et des temps de calcul particulièrement longs (jusqu'à 2,5 heures par modèle PPO sur 2 millions de steps), l'exploration poussée de l'environnement multi-agent impliquant plusieurs bergers simultanés (Niveau 4) n'a pas pu être menée à son terme. Nos ressources de calcul ont été priorisées sur l'extraction statistique rigoureuse sur 1000 épisodes, et l'optimisation comparative des modèles PPO et DQN sur les trois premiers niveaux.

Conclusion

Ce projet met en lumière la supériorité systématique des réseaux de neurones exploitant des vecteurs d'états continus (PPO) par rapport aux approches purement visuelles (DQN) pour des tâches de navigation géométrique complexe.




Figure 5 : Bilan global des taux de succès sur 1 mouton.

L'analyse de nos résultats est d'autant plus frappante lorsque l'on observe la distribution des récompenses moyennes avec leurs barres d'erreur (écart-type).




Figure 6 : Bilan global des récompenses moyennes et stabilité (Écart-type).

Comme l'illustre la Figure 6, PPO obtient non seulement des scores plus élevés (barres bleues), mais l'amplitude de ses moustaches d'incertitude est beaucoup plus resserrée que celle de DQN, démontrant une stabilité comportementale nettement supérieure.

Nous avons prouvé que le Curriculum Learning est une méthode redoutable pour accélérer l'adaptation à de nouvelles dynamiques (mouvements), bien qu'elle puisse créer des biais cognitifs si l'environnement subit un changement topologique trop brusque (obstacles). Enfin, l'échec de la généralisation sur plusieurs moutons souligne que la puissance d'un algorithme est intimement liée à la qualité de sa *State Représentation*. Pour résoudre ce problème à grande échelle, il serait impératif de fournir à l'agent des métriques collectives, telles que le centre de gravité et le rayon de dispersion du troupeau.

Perspectives et Améliorations Futures

Outre la refonte du vecteur d'observation pour la gestion multi-agent abordée précédemment, une piste d'optimisation très prometteuse consisterait à appliquer la logique du *Curriculum Learning* non plus sur la topologie de l'environnement, mais sur la **précision de la tâche**.

En réduisant progressivement le rayon de la zone cible (le *goal*) au fil des itérations d'entraînement, nous pourrions forcer l'agent à affiner sa politique de contrôle continu. Cette approche de spécialisation progressive permettrait de guider l'intelligence artificielle d'un comportement de rassemblement global vers un contrôle de haute précision, aboutissant à un agent capable de guider le troupeau vers un enclos de taille très restreinte avec une précision millimétrique.